Базовые методы обработки данных с использованием Python

Лекция 7. Форматы файлов, CSV, JSON. Работа с файлами в Python. Модуль OS. Файловые СУБД, SQLite. Операции CRUD в SQLite

Киреев Василий Сергеевич к.т.н., доцент

Колоночные vs строчные форматы файлов

Существует два основных способа организации данных: строки и столбцы. Выбор одного из них в значительной степени определяет эффективность хранения и запроса данных.

Строка - данные организованы по записям. Это более "традиционный" способ организации и управления данными. Все данные, относящиеся к конкретной записи, хранятся рядом. Другими словами, данные каждой строки расположены таким образом, что последний столбец строки хранится рядом с первой записью столбца последующей строки данных.

Колоночный - значения каждого столбца (поля) таблицы хранятся рядом друг с другом. Это означает, что подобные элементы группируются и хранятся рядом друг с другом. Внутри полей сохраняется порядок чтения - это сохраняет возможность связывать данные с записями.

Колоночные vs строчные форматы файлов



Форматы файлов. CSV

CSV - это текстовый формат, в котором в качестве разделителя записей используется новая строка и необязательный заголовок. Он легко редактируется вручную и очень понятен с человеческой точки зрения.

CSV не поддерживает эволюцию схемы, хотя иногда заголовок опционально рассматривается как схема данных. В своем сложном виде он не поддается разбиению на части, поскольку не содержит определенного символа, на который можно было бы опереться, чтобы разделить текст, сохранив его актуальность.

Форматы файлов. JSON

JSON (JavaScript object notation) - это текстовый формат, содержащий запись, которая может быть представлена в нескольких формах (строка, целое число, булевы символы, массив, объект, ключ-значение, вложенные данные...). Будучи человеко- и машиночитаемым, JSON является относительно легким форматом и широко используется в веб-приложениях.

Он широко поддерживается многими программами и сравнительно прост для реализации в различных языках. JSON изначально поддерживает процессы сериализации и десериализации. Его основное неудобство связано с тем, что он не может быть разделен на части.

Операции ввода-вывода в Python

Для выполнения стандартных операций ввода-вывода в Python используются встроенные функции input() и print(). Программа Python взаимодействует с этими устройствами ввода-вывода через стандартные потоковые объекты stdin и stdout, определенные в модуле sys.

Функция input() считывает байты со стандартного устройства потока ввода, т.е. с клавиатуры.

Операции ввода-вывода в Python. Методы работы с файлами

file.close()	Закрывает файл. Закрытый файл больше не может быть прочитан или записан.
file.flush()	Промыть внутренний буфер, подобно fflush в stdio. Для некоторых файлоподобных объектов это может быть неактуально.
file_fileno()	Возвращает целочисленный дескриптор файла, который используется базовой реализацией для запроса операций ввода-вывода от операционной системы.
file.isatty()	Возвращает True, если файл подключен к tty(-подобному) устройству, иначе False.
next(file)	Возвращает следующую строку из файла при каждом вызове.
file.read([size])	Читает из файла не более size байт (меньше, если чтение достигает EOF до получения size байт).

Операции ввода-вывода в Python. Режимы открытия файлов

file.readli	nes([sizehint])	Считывает файл до EOF с помощью readline() и возвращает список, содержащий строки. Если присутствует необязательный аргумент sizehint, то вместо чтения до EOF считываются целые строки общим размером примерно sizehint байт (возможно, после округления до размера внутреннего буфера).
file.seek(c	offset[, whence])	Устанавливает текущую позицию файла
file.tell()		Возвращает текущую позицию файла
file.truncate([size])		Усекает размер файла. Если присутствует необязательный аргумент size, то файл усекается до (не более) этого размера.
file.write(str)	Записывает в файл строку. Возвращаемое значение отсутствует.
file.writelines(sequence)		Записывает в файл последовательность строк. Последовательность может быть любым итерируемым объектом, производящим строки, обычно это список строк.

Операции ввода-вывода в Python. Запись в файл

Чтобы записать данные в файл в Python, необходимо открыть файл. Любой объект, взаимодействующий с входной и выходной парой, называется объектом File. Встроенная функция Python open() возвращает файловый объект.

После получения объекта file с помощью функции open() можно использовать метод write() для записи любой строки в файл, представленный объектом file. Важно отметить, что строки Python могут содержать не только текст, но и двоичные данные. Метод write() не добавляет символ новой строки ('\n') в конец строки.

Операции ввода-вывода в Python. Чтение из файла

Чтобы программно прочитать данные из файла с помощью Python, его необходимо сначала открыть. Для этого можно воспользоваться встроенной функцией open().

Ниже приведены сведения о параметрах:

- file_name Аргумент имя_файла представляет собой строковое значение, содержащее имя файла, к которому требуется получить доступ.
- access_mode Access_mode определяет режим, в котором должен быть открыт файл, т.е. чтение, запись, добавление и т.д. Это необязательный параметр, и по умолчанию используется режим доступа к файлу read (r).

Операции ввода-вывода в Python. Режимы открытия файлов

r	Открывает файл только для чтения. Указатель файла помещается в начало файла. Это режим по умолчанию.
rb	Открывает файл только для чтения в двоичном формате. Указатель файла помещается в начало файла. Это режим по умолчанию.
r+	Открывает файл как для чтения, так и для записи. Указатель файла помещается в начало файла.
rb+	Открывает файл для чтения и записи в двоичном формате. Указатель файла помещается в начало файла.
w	Открывает файл только для записи. Перезаписывает файл, если он существует. Если файл не существует, создается новый файл для записи.
b	Открывает файл в двоичном режиме

Операции ввода-вывода в Python. Режимы открытия файлов

t	Открывает файл в текстовом режиме (по умолчанию)		
+	открыть файл для обновления (чтения и записи)		
wb	Открывает файл для записи только в двоичном формате. Перезаписывает файл, если он существует. Если файл не существует, создается новый файл для записи.		
w+	Открывает файл как для записи, так и для чтения. Перезаписывает существующий файл, если он существует. Если файл не существует, создает новый файл для чтения и записи.		
wb+	Открывает файл для записи и чтения в двоичном формате. Перезаписывает существующий файл, если он существует. Если файл не существует, создается новый файл для чтения и записи.		
а	Открывает файл для добавления. Указатель файла находится в конце файла, если файл существует. То есть файл находится в режиме добавления. Если файл не существует, то создается новый файл для записи.		

Одновременное чтение/запись в Python

Когда файл открыт для записи (с помощью 'w' или 'a'), чтение из него невозможно, и наоборот. Это приводит к ошибке UnSupportedOperation. Перед выполнением другой операции необходимо закрыть файл.

Для того чтобы выполнить обе операции одновременно, необходимо добавить в параметр mode символ '+'. Таким образом, режим 'w+' или 'r+' позволяет использовать как методы write(), так и read() без закрытия файла.

Объект File также поддерживает функцию seek(), позволяющую перемотать поток на любую нужную позицию байта.

Одновременное чтение/запись в Python. Метод seek()

Метод seek() устанавливает текущую позицию файла по смещению. Аргумент whence необязателен и по умолчанию равен 0, что означает абсолютное позиционирование файла, другие значения - 1, что означает поиск относительно текущей позиции, и 2 - поиск относительно конца файла. Возвращаемое значение отсутствует. Обратите внимание, что если файл открыт для добавления с помощью 'a' или 'a+', то все операции seek() будут отменены при следующей записи.

Если файл открыт только для записи в режиме добавления с использованием 'a', то этот метод, по сути, не работает, но он остается полезным для файлов, открытых в режиме добавления с включенным чтением (режим 'a+').

Если файл открыт в текстовом режиме с помощью команды 't', то допустимы только смещения, возвращаемые функцией tell(). Использование других смещений приводит к неопределенному поведению.

Модуль OS

Модуль OS Python предоставляет возможность установить взаимодействие между пользователем и операционной системой. Методы, включенные в неиј позволяют определять тип операционной системы, получать доступ к переменным окружения, управлять директориями и файлами, управлять процессами. OS входит в состав стандартных служебных модулей.

Модуль OS. Работа с текущим каталогом

Функция *os.chdir* — меняет каталог, который в данный момент используется в сессии. *os.getcwd()* показывает текущий каталог.

```
1 os.chdir(r"/content/")
2 print(os.getcwd())
3 os.chdir(r"/content/sample_data")
4 print(os.getcwd())
```

```
/content
/content/sample_data
```

Модуль OS. Создание папок

os.mkdir() позволяет создать одну папку. os.makedirs() создает промежуточные папки в пути, если их там нет

```
1 os.mkdir("TEST")
2 path = r'/content/TEST1'
3 os.mkdir(path)
```

Модуль OS. Удаление файлов и папок

Функции *os.remove()* и *os.rmdir()* используются для удаления файлов и каталогов соответственно.

```
1 path = r"/content/"
2 os.chdir(path)
3 !echo 'dfsdf' > test.txt
4 print(list(os.walk(path))[0])
5 os.remove("test.txt")
6 print(list(os.walk(path))[0])

C ('/content/', ['.config', 'sample_data', 'TEST1'], ['test.txt'])
('/content/', ['.config', 'sample_data', 'TEST1'], [])
```

Модуль OS. Итерация по каталогу

Метод *os.walk()* дает нам получить доступ ко всем подкаталогам и файлам для выбранного пути.

```
path = r'/content/sample_data'
2 list(os.walk(path))

[('/content/sample_data',
    ['TEST'],
    ['README.md',
    'anscombe.json',
    'california_housing_train.csv',
    'mnist_train_small.csv',
    'mnist_test.csv',
    'california_housing_test.csv']),
    ('/content/sample_data/TEST', [], [])]
```

Модуль OS. Переименование файлов и папок

Функция *os.rename()* применяется тогда, когда нужно переименовать файл или папку.

```
1 os.chdir(r"/content/")
2 print(os.getcwd())
3 os.chdir(r"/content/sample_data")
4 print(os.getcwd())
```

/content
/content/sample_data

Модуль OS.PATH

os.path - модуль, реализующий некоторые полезные функции на работы с путями. Функция basename вернет название файла пути. Или последней вложенной папки.

```
1 path = r'/content/sample_data'
2 os.path.basename(path)

[→ 'sample_data'
```

Модуль OS. Часть каталога пути

os.path.dirname - возвращает только часть каталога пути.

- 1 os.path.dirname(r'/content/sample_data/california_housing_train.csv')
- '/content/sample_data'

Модуль OS. Проверка существования файла

Функция exists говорит, существует ли файл, или нет.



1 os.path.exists(r'/content/sample_data/california_housing_train.csv')

True

Модуль OS. Проверка существования

Методы *isdir* и *isfile* тесно связаны с методом exists, так как они также тестируют присутствие или отсутствие файлов или папок на тех или иных путях. Однако, *isdir* проверяет только пути к папкам, а *isfile*, соответственно, к файлам.

```
1 print(os.path.isfile(r'/content/sample_data/california_housing_train.csv'))
2 print(os.path.isdir(r'/content/sample_data/california_housing_train.csv'))

True
False
```

Модуль OS. Создание строк с путями

Метод *join* позволяет совместить несколько путей при помощи присвоенного разделителя.

```
1 print(os.path.join(r'/content/sample_data/', 'california_housing_train.csv'))
```

/content/sample_data/california_housing_train.csv

Модуль OS. Разделение строки пути

Метод *split* разъединяет путь на кортеж, который содержит и файл и каталог.

```
1 os.path.split(r'/content/sample_data/california_housing_train.csv')
    ('/content/sample_data', 'california_housing_train.csv')
```

Модуль OS. Просмотр текущего каталога

Функция *os.listdir* – показывает содержимое текущего каталога.

```
1 list(os.listdir(r'/content/sample_data/'))
```

Модуль OS. Размер файла или папки

Функция *getsize* используется для измерения объема директорий и файлов.

```
1 print(os.path.getsize(r'/content/sample_data/california_housing_train.csv'))

□ 1706430
```

Модуль OS. Свойства файла или папки

Функция *os.stat* – показывает свойства файла или папки.

Device: 38

Модуль OS. Подпроцессы в ОС

Функция *os.fork* – позволяет выделять подпроцессы в ОС.

```
1 import os
2
3 pid = os.fork()
4
5 if pid:
6    print('Child process id:', pid)
7 else:
8    print('I am the child')
Child process id: 367
I am the child
```

Модуль OS. Представление пути в ФС

Функция *os.fspath* — возвращает представление пути в файловой системе.

```
1 os.fspath(r'/content/sample_data/california_housing_train.csv')
```

□→ '/content/sample_data/california_housing_train.csv'

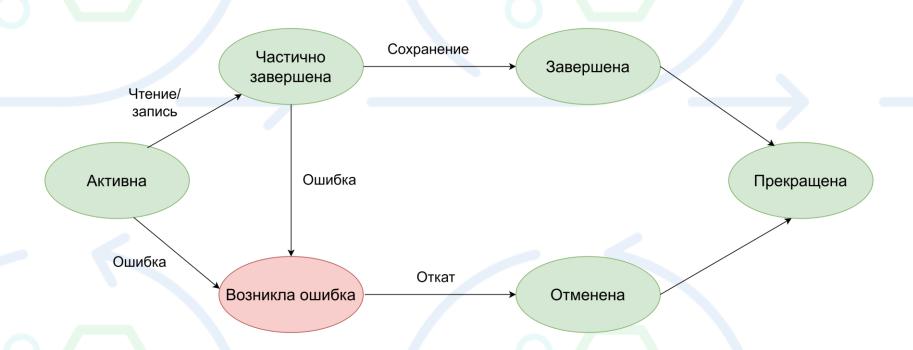
Файловая СУБД SQLite

SQLite — это высокоэффективный , бессерверный и автономный движок базы данных SQL, который выделяется своей простотой и легкостью интеграции. Разработанный для встраивания в приложения, SQLite устраняет необходимость в отдельных процессах сервера базы данных и сложных конфигурациях.

SQLite была разработана в 2000 году Д. Ричардом Хиппом, как легкая и простая СУБД, которую можно было бы легко встраивать в другие приложения. Она была создана как альтернатива более сложным и тяжеловесным системам баз данных, таким как MySQL и PostgreSQL. SQLite поддерживает транзакции ACID.

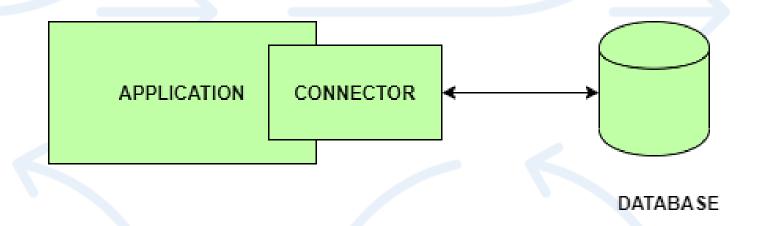
Транзакции ACID

Транзакция — это набор операций, которые выполняются как единое, атомарное целое. Транзакции обеспечивают согласованность данных, гарантируя, что либо все операции в рамках транзакции фиксируются в базе данных, либо ни одна из них. Термин ACID означает атомарность, согласованность, изоляцию и долговечность.



Файловая СУБД SQLite. Бессерверность

SQLite не требует сервера для работы. База данных SQLite объединена с приложением, которое обращается к базе данных. База данных SQLite считывает и записывает данные непосредственно из файлов базы данных, хранящихся на диске, и приложения взаимодействуют с этой базой данных SQLite.



Достоинства SQLite

- Простота использования: SQLite очень легко начать использовать, так как он не требует установки или настройки. Вы можете просто включить библиотеку в свой проект и начать ее использовать.
- Встраиваемость: SQLite разработан для встраивания в другие приложения. Это автономный, бессерверный движок базы данных, что означает, что вы можете включить его в свое приложение без необходимости в отдельном сервере базы данных.
- Легковесность: SQLite очень легкая СУБД с небольшим размером библиотеки (обычно менее 1 МБ). Это делает ее хорошо подходящей для использования в приложениях, где база данных встроена непосредственно в двоичный файл приложения, например, в мобильных приложениях.
- Бессерверность: SQLite это серверный движок базы данных, что означает, что нет необходимости настраивать и поддерживать отдельный процесс сервера базы данных. Это упрощает развертывание и управление, поскольку нет дополнительных зависимостей, о которых нужно беспокоиться.
- Кроссплатформенность: SQLite доступен на многих платформах, включая Linux, macOS и Windows, что делает его хорошим выбором для кроссплатформенной разработки.
- Автономность: SQLite хранит все данные в одном файле в файловой системе, что упрощает копирование или резервное копирование базы данных.
- Высокая надежность: SQLite широко тестировалась и использовалась в производственных системах на протяжении многих лет и имеет репутацию надежного и производительного ядра базы данных.

Ограничения SQLite

- Ограниченный параллелизм: SQLite использует файловую блокировку для управления доступом к базе данных, что может привести к проблемам с производительностью, когда несколько клиентов пытаются одновременно читать и писать в базу данных. Это делает его менее подходящим для использования в системах с высокой степенью параллелизма.
- Нет поддержки хранимых процедур: SQLite не поддерживает хранимые процедуры, которые являются предварительно скомпилированными операторами SQL, которые могут быть выполнены на сервере. Это означает, что весь код SQL должен быть отправлен на сервер и скомпилирован во время выполнения, что может быть менее эффективно, чем использование хранимых процедур.
- Нет поддержки триггеров: SQLite не поддерживает триггеры, которые являются действиями базы данных, которые автоматически запускаются указанными событиями (например, вставкой строки в таблицу). Это означает, что вам придется вручную реализовать любую логику, которая должна запускаться определенными событиями.
- Ограниченная поддержка типов данных: SQLite имеет относительно небольшой набор типов данных по сравнению с другими движками баз данных. Он не поддерживает многие из более продвинутых типов данных, таких как массивы и JSON, которые доступны в других базах данных.
- Ограниченная масштабируемость: SQLite не предназначена для работы в качестве высококонкурентной, высокоскоростной СУБД. Она больше подходит для использования в системах меньшего масштаба с низким уровнем параллелизма и может не иметь возможности масштабироваться для обработки очень больших объемов данных или очень высоких уровней параллелизма.

Типы данных в SQLite

	Тип	Описание	Соответствие другим типам
	NULL	Значение равно NULL.	
	INTEGER	Значение представляет собой целое число со знаком, хранящееся в 1, 2, 3, 4, 6 или 8 байтах в зависимости от величины значения.	INT, INTEGER, TINYINT, SMALLINT, MEDIUMINT, BIGINT, UNSIGNED BIG INT, INT2, INT8
	REAL	Значение представляет собой значение с плавающей запятой, хранящееся как 8-байтовое число с плавающей запятой IEEE.	
	TEXT	Значение представляет собой текстовую строку, сохраненную с использованием кодировки базы данных (UTF-8, UTF-16BE или UTF-16LE).	
	BLOB	Значение представляет собой блок данных, хранящийся точно в том виде, в котором он был введен.	

Язык структурированных запросов SQL

Язык структурированных запросов (SQL) — это язык программирования для хранения и обработки информации в реляционной базе данных. Реляционная база данных хранит информацию в табличной форме со строками и столбцами, представляющими различные атрибуты данных и различные связи между значениями данных.

Инструкции SQL можно использовать для хранения, обновления, удаления, поиска и извлечения информации из базы данных. Можно также использовать SQL для поддержания и оптимизации производительности базы данных.

Языки DDL, DQL, DML

DDL или язык определения данных, состоит из команд SQL, которые могут использоваться для определения, изменения и удаления структур базы данных, таких как таблицы, индексы и схемы. Он имеет дело с описаниями схемы базы данных и используется для создания и изменения структуры объектов базы данных в базе данных

Операторы DQL используются для выполнения запросов к данным в объектах схемы. Целью команды DQL является получение некоторого отношения схемы на основе переданного ей запроса. Эта команда позволяет извлекать данные из базы данных для выполнения операций с ними. Когда SELECT запускается для таблицы или таблиц, результат компилируется в дополнительную временную таблицу, которая отображается или, возможно, принимается программой.

Команды SQL, которые имеют дело с манипулированием данными, присутствующими в базе данных, принадлежат к DML или языку манипулирования данными, и это включает в себя большинство операторов SQL. Это компонент оператора SQL, который управляет доступом к данным и к базе данных. В основном операторы DCL группируются с операторами DML.

DDL, DQL, DML B SQLite

Язык	Команда	Описание
	CREATE TABLE	создает новую таблицу в базе данных.
	ALTER TABLE	изменяет существующую таблицу в базе данных.
DDL	DROP TABLE	удаляет таблицу из базы данных.
	CREATE INDEX	создает новый индекс для таблицы.
	DROP INDEX	удаляет индекс из таблицы.
	INSERT INTO	вставляет новую строку в таблицу.
DQL	UPDATE	обновляет данные в одной или нескольких строках таблицы.
	DELETE FROM	удаляет одну или несколько строк из таблицы.
	SELECT	извлекает данные из одной или нескольких таблиц в базе данных.
DMI	JOIN	извлекает данные из нескольких таблиц на основе общего поля.
DML	GROUP BY	группирует результаты запроса по одному или нескольким полям.
	HAVING	фильтрует результаты запроса на основе условия

Работа с SQLite в Python. Метод connect.

Подключение к базе данных SQLite можно установить с помощью метода connect(), передавая имя базы данных, к которой необходимо получить доступ, в качестве параметра. Если эта база данных не существует, то она будет создана.

```
import sqlite3
try:
  sqliteConnection = sqlite3.connect('sql.db')
  cursor = sqliteConnection.cursor()
  print('Инициализация БД')
  query = 'select sqlite_version();'
  cursor.execute(query)
  result = cursor.fetchall()
  print('Версия SQLite: {}'.format(result))
  cursor.close()
except sqlite3.Error as error:
  print('Возникла ошибка - ', error)
finally:
  if sqliteConnection:
    sqliteConnection.close()
    print('Соединение с SQLite закрыто')
```

Инициализация БД

Версия SQLite: [('3.37.2',)]

Соединение с SQLite закрыто

Работа с SQLite в Python. Метод connect.

Подключение к базе данных SQLite можно установить с помощью метода connect(), передавая имя базы данных, к которой необходимо получить доступ, в качестве параметра. Если эта база данных не существует, то она будет создана.

Шаблон запроса SELECT

```
statement> ::= [WITH <common_table_expression> [,...n]]
<SELECT
<query_expression> [ ORDER BY { order_by_expression | column_position [ ASC |
DESC ] } [ ,...n ] ] [ COMPUTE { { AVG | COUNT | MAX | MIN | SUM } ( expression ) }
[,...n] [BY expression [,...n]] [ <FOR Clause>] [OPTION ( <query_hint> [,...n]) ]
<query_expression> ::= { <query_specification> | ( <query_expression> ) } [ {
UNION [ ALL ] | EXCEPT | INTERSECT } <query specification> | (
<query_expression> ) [...n ] ] <query_specification> ::= SELECT [ ALL | DISTINCT ]
[TOP (expression) [PERCENT] [ WITH TIES ] ] < select_list > [ INTO new_table ] [
FROM { <table_source> } [ ,...n ] ] [ WHERE <search_condition> ] [ <GROUP BY> ] [
HAVING < search condition > ]
```

Работа с SQLite в Python. Метод insert into.

Оператор SQL INSERT INTO из SQL используется для вставки новой строки в таблицу. Существует два способа использования оператора INSERT INTO для вставки строк: Только значения: указание только значений данных, которые необходимо вставить, без имен столбцов; имена столбцов и значения.

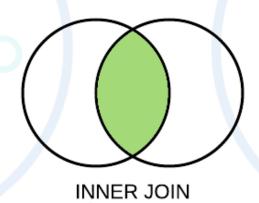
```
import sqlite3
conn = sqlite3.connect('sql.db')
cursor = conn.cursor()
table ="""CREATE TABLE STUDENT(NAME VARCHAR(255), CLASS
VARCHAR(255),
SECTION VARCHAR(255));"""
cursor.execute(table)
cursor.execute("'INSERT INTO STUDENT VALUES ('Иванов', '7th', 'A')"')
cursor.execute("'INSERT INTO STUDENT VALUES ('Петров', '8th', 'B')"')
cursor.execute("'INSERT INTO STUDENT VALUES ('Сидоров', '9th', 'C')"')
data=cursor.execute("'SELECT * FROM STUDENT''')
for row in data:
    print(row)
conn.commit()
conn.close()
```

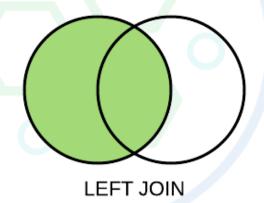
```
('Иванов', '7th', 'A')
('Петров', '8th', 'B')
('Сидоров', '9th', 'C')
```

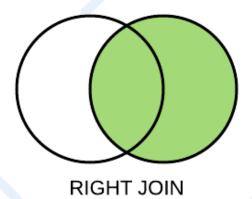
Виды соединений в SQLite

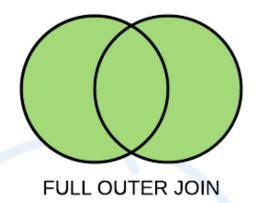
Команда	Описание
INNER JOIN (JOIN)	выдает записи, имеющие общие атрибуты в обеих таблицах.
LEFT JOIN	возвращает все записи из левой таблицы и только общие записи из правой таблицы.
RIGHT JOIN	возвращает все записи из правой таблицы и только общие записи из левой таблицы.
ПОЛНОЕ ВНЕШНЕЕ ОБЪЕДИНЕНИЕ	возвращает все записи, если в левой или правой таблице есть общий атрибут.
CROSS JOIN	объединяет записи одной таблицы со всеми остальными записями другой таблицы.

Виды соединений в SQLite









Аналитические функции в SQLite

Команда	Описание	
MAX()	Возвращает максимальное значение в выражении. Возвращает такое же значение, как и expression.MAX ([ALL DISTINCT] expression) Выражение может быть константой, именем столбца или функцией, а также любым сочетанием арифметических, побитовых и строковых операторов. Функцию MAX можно использовать с колонками типа numeric, character и datetime, но не с колонками типа bit.	
MIN()	Возвращает минимальное значение выражения. Возвращает такое же значение, как и expression.MIN ([ALL DISTINCT] expression) Выражение может быть константой, именем столбца или функцией, а также любым сочетанием арифметических, побитовых и строковых операторов. Функцию MIN можно использовать с колонками типа numeric, character и datetime, но не с колонками типа bit.	
SUM()	Возвращает сумму всех (либо только уникальных) значений в выражении. Функция SUM может быть использована только для числовых колонок. Сумма всех значений выражения expression представлена в наиболее точном формате данных, используемом в выражении expression.SUM ([ALL DISTINCT] expression)	

Спасибо за внимание!